

KI-Detektoren und ad-hominem-Argumentation

Strukturelle Verwandtschaft alter und neuer Manipulations-Muster

Johann Pascher

Mai 2026

Vorbemerkung

Dieser Text geht auf eine Diskussion in der Mailingliste des *Information Physics Institute* (Mai 2026) zurück. Peter Austin schilderte, dass seine eigenen E-Mails von KI-Detektoren regelmäßig mit Werten über 50 % als KI-generiert markiert werden – auch dann, wenn sie in persönlicher Korrespondenz entstehen und keinerlei KI-Unterstützung enthalten. Die Frage in der Runde war zunächst praktisch: was tun gegen diese falschen Positiv-Treffer.

Bei näherer Betrachtung zeigt sich, dass die Frage nicht primär technisch ist, sondern methodisch und psychologisch. KI-Detektoren stehen nicht am Anfang eines neuen Phänomens, sondern am vorläufigen Ende einer alten Linie: jener Argumentations-Muster, die ablehnen, ohne sich auf die Sache einzulassen. Dieses Dokument beschreibt die strukturelle Verwandtschaft und benennt den psychologischen Mechanismus, der das Muster antreibt.

1 Der Widerspruch in der Anforderung

Im Zentrum der gegenwärtigen Debatte steht ein offener Widerspruch:

- Auf der einen Seite verlangen wir präzise, fehlerfreie, klar strukturierte Texte. Das ist seit jeher der Standard wissenschaftlicher und fachlicher Kommunikation.
- Auf der anderen Seite gilt nun *die Abwesenheit von Fehlern* selbst als verdächtig. Ein Text mit niedriger Perplexity, gleichmäßiger Satzstruktur und sauberen Übergängen wird von Detektoren als KI markiert.

Wörtlich genommen ist das eine **Aufforderung, schlechter zu schreiben**: genug Roughness produzieren, um nicht aufzufallen, genug Variation, um nicht als Maschine zu gelten. Das kann kein methodischer Standard sein.

Die Belege für diese Schieflage sind klar dokumentiert. Die Stanford-Studie von Weixin Liang, Mert Yuksekgonul, Yining Mao, Eric Wu und James Zou *GPT detectors are biased against non-native English writers* (Patterns, Vol. 4, Nr. 7, Artikel 100779, 14. Juli 2023; arXiv:2304.02819) zeigte: Sieben weit verbreitete GPT-Detektoren klassifizierten *über die Hälfte* der TOEFL-Aufsätze nicht-muttersprachlicher Englisch-Lerner als „KI-generiert“, während dieselben Detektoren bei US-amerikanischen Achtklässler-Aufsätzen nahezu perfekte Genauigkeit erreichten. Der Grund: nicht-muttersprachliche Texte haben typischerweise eine niedrigere Perplexity, weil das Vokabular eingeschränkter und die Satzstrukturen einfacher gewählt werden – genau dieses Merkmal teilen sie mit maschinell generiertem Text.

OpenAI selbst – der Hersteller von ChatGPT – veröffentlichte im Januar 2023 einen *AI Classifier*, der genau dieses Problem lösen sollte. Sechs Monate später, am 20. Juli 2023, wurde das Werkzeug eingestellt.

Der offizielle Grund laut OpenAI: nur 26 % der tatsächlich KI-generierten Texte wurden korrekt erkannt, und in 9 % der Fälle wurden menschliche Texte fälschlich als KI markiert. Bei einer Trefferquote unter 50 % ist ein Detektor schlechter als ein Münzwurf.

Wer als Techniker, Wissenschaftler oder Nicht-Muttersprachler viel überarbeitet, schreibt notwendigerweise klarer und strukturierter als Gelegenheitsschreiber. Genau dieses Schreiben wird systematisch geflaggt.

2 Substanz statt Stil

Die eigentliche Unterscheidung zwischen menschlich und maschinell generiertem Inhalt liegt nicht im Stil, sondern in der Substanz.

KI-Texte sind charakterisiert nicht durch ihre Form, sondern durch eine spezifische inhaltliche Schwäche: sie sind oft schlüssig klingende Argumentationen, die auf *halluzinierten Fakten*, *erfundenen Zitaten* und *selbstsicher vorgetragenen, aber inhaltlich leeren Herleitungen* aufgebaut sind. Die sprachliche Politur ist real; die Substanz ist erfunden.

Ein kritischer Leser, der den Gegenstand versteht, erkennt diese Schwäche – nicht an Oberflächenmerkmalen, sondern daran, dass die Behauptungen bei genauerer Prüfung nicht halten. Eine statistische Maschine kann diesen Unterschied prinzipiell nicht sehen, denn er ist kein Oberflächenmerkmal.

Folge: Wer Inhalt prüfen will, muss Inhalt verstehen können. Detektoren können das nicht. Sie können nur Symptome zählen.

3 Der Checker-Nutzer als eigentlicher Fehlanwender

Hier zeigt sich eine Inversion, die in der Debatte selten ausgesprochen wird. Wer einen KI-Detektor benutzt, statt selbst zu lesen, **delegiert seine eigene Urteilstkraft an einen Algorithmus.**

Damit ist der Checker-Nutzer tiefer in der KI-Abhängigkeit als der Autor, der KI bewusst als Werkzeug nutzt:

Rolle	Was tut die Person	Wer hat das Urteil
Autor mit KI-Werkzeug	Substanz selbst, Sprache mit KI-Hilfe	Mensch
Reviewer mit Detektor	Score ablesen, Urteil von Maschine übernehmen	Maschine

Der Vorwurf „Sie haben KI benutzt“ kommt also häufig von genau der Person, die ihre eigene kritische Funktion bereits an KI abgegeben hat. Sie wirft dem Autor vor, was sie selbst tut – ohne Bewusstsein, dass sie es tut.

4 KI als Filter, nicht als Orakel

Eine wichtige Differenzierung ist nötig. Auch sorgfältige Wissensarbeiter nutzen KI – für Zusammenfassungen, für Sprachformalisierung, für Vorsortierung großer Textmengen. Das ist nicht das Problem. Das Problem ist *die Art* der Nutzung.

KI als Filter (Triage):

- KI liest große Textmengen vor und fasst zusammen.

- Der Mensch liest die Zusammenfassung und entscheidet: passt das, oder muss ich selbst genauer hinsehen?
- Bei Unklarheit oder Auffälligkeit: der Mensch geht selbst ins Detail.
- Das Endurteil liegt immer beim Menschen.

KI als Orakel (Delegation):

- KI gibt einen Score, eine Klassifikation, eine Wahrheit.
- Der Score wird übernommen.
- Keine eigene Prüfung der Substanz.
- Keine Bereitschaft, bei Auffälligkeiten selbst zu lesen.

Die KI-Nutzung als **Filter** ist methodisch unproblematisch – sie entspricht der seit jeher üblichen Praxis, größere Textmengen durch Abstracts, Bibliographien oder Assistenten vorsortieren zu lassen. Die KI-Nutzung als **Orakel** ist methodisch fatal: sie ersetzt das Urteil, statt es zu unterstützen.

Detektoren sind das Paradebeispiel der Orakel-Nutzung. Sie liefern eine Zahl, die akzeptiert oder ignoriert werden kann – aber keine Substanz, die geprüft werden könnte.

5 Strukturelle Unmöglichkeit der Inhaltsbeurteilung

Hier liegt die technische Pointe, die der ganzen Detektor-Konstruktion den Boden entzieht.

Ein KI-Detektor behauptet implizit: „Ich kann erkennen, ob ein Text von einer KI stammt.“ Dafür müsste er etwas können, was die KI selbst nicht kann:

- KI weiß nicht, ob eine Behauptung wahr ist.
- KI weiß nicht, ob eine Argumentation hält.
- KI erkennt nicht ihre eigenen Halluzinationen.

Wenn die KI selbst inhaltlich überfordert ist, kann ein Detektor - der ebenfalls eine KI ist - erst recht nicht inhaltlich urteilen. Er kann nur Oberflächenmerkmale messen: Wortwahrscheinlichkeiten (Perplexity), Satzlängen-Variation (Burstiness), Häufigkeit bestimmter Übergangswörter.

Die Konstruktion löst sich logisch selbst auf:

Wer Inhalt prüfen will, muss Inhalt verstehen können. Detektoren sind KI. KI kann keinen Inhalt verstehen. Also können Detektoren nicht prüfen, was sie zu prüfen vorgeben.

Ein Detektor, der wirklich Inhalt prüfen könnte, wäre keine KI mehr – er wäre ein *kritisch denkender Mensch mit Sachverstand*. Genau das soll der Detektor aber ersetzen. Der Anspruch ist selbstwidersprüchlich.

5.1 Eine Analogie

Niemand würde jemandem glauben, der sagt: „Ich kann erkennen, ob ein Mathebuch von einem inkompetenten Autor stammt – ohne dass ich selbst Mathematik kann. Ich messe nur die Häufigkeit bestimmter Wörter.“ Aber genau das tun KI-Detektoren: Sie behaupten, **Substanz** durch **Form-Statistik** zu beurteilen.

Das ist derselbe Kategorienfehler wie bei Phrenologie (Schädelform gleich Charakter) oder Lügendetektor (Schweißproduktion gleich Wahrheit): *Messung von Oberflächen-Korrelaten, dargestellt als Messung der eigentlichen Größe.*

6 Verwandtschaft mit ad-hominem-Argumentation

Bis hierhin war die Argumentation technisch. Nun kommt die strukturelle Pointe: KI-Detektoren sind kein neues Phänomen.

Sie machen mit Texten dasselbe, was ad-hominem-Argumentation mit Personen macht.

Ad-hominem-Argumentation	KI-Detektor
greift den Sprecher an, nicht das Argument	bewertet die Form, nicht den Inhalt
wer hat das gesagt?	wer (oder was) hat das geschrieben?
umgeht die inhaltliche Auseinandersetzung	umgeht die inhaltliche Prüfung
ist bequem – kein Verstehen nötig	ist bequem – kein Lesen nötig
ersetzt Denken durch Verdacht	ersetzt Lesen durch Score

Beides folgt demselben Muster: **Verlagerung der Bewertung von der Sache auf eine Eigenschaft der Quelle.** Statt zu prüfen, ob etwas stimmt, wird gefragt, woher es kommt – und aus der Herkunft auf die Gültigkeit geschlossen.

In der Logik heißt das seit Jahrhunderten *genetischer Fehlschluss*. Aristoteles hat ad-hominem-Argumente bereits in den *Sophistischen Widerlegungen* als Fehlschluss beschrieben. Arthur Schopenhauer behandelt das verwandte *argumentum ad personam* in seiner *Eristischen Dialektik* als Scheinargument, das den Inhalt umgeht. Der Mechanismus ist 2400 Jahre alt; die technische Vollendung in Software-Form ist neu.

7 Kognitive Dissonanz als Antrieb des Musters

Warum funktioniert dieses Muster so zuverlässig? Die Antwort liefert Leon Festingers *Theory of Cognitive Dissonance* (Stanford University Press, 1957), eine der einflussreichsten Arbeiten der Sozialpsychologie des 20. Jahrhunderts.

7.1 Festingers Grundbeobachtung

Festinger entwickelte die Theorie aus einer ungewöhnlichen empirischen Beobachtung. In *When Prophecy Fails* (gemeinsam mit Henry W. Riecken und Stanley Schachter, University of Minnesota Press, 1956) dokumentiert er das Verhalten einer Weltuntergangs-Sekte, die einen konkreten Termin für das Ende der Welt vorhergesagt hatte. Als der Termin verstrich, ohne dass etwas geschah, *verstärkte* sich der Glaube der Mitglieder, statt zu zerfallen. Sie deuteten das Ausbleiben des Untergangs als Beweis, dass ihre Glaubensgemeinschaft die Welt gerettet hatte.

Festingers Schlussfolgerung: Wenn zwei Überzeugungen unvereinbar sind, entsteht psychischer Druck (*Dissonanz*). Dieser Druck führt nicht zwingend zur Korrektur der falschen Überzeugung – oft führt er zur *Umdeutung der Realität*, so dass die ursprüngliche Position bestätigt bleibt.

7.2 Anwendung auf den Detektor-Kontext

In der KI-Detektor-Situation entsteht typischerweise diese Dissonanz beim Reviewer:

Überzeugung A	Überzeugung B (auslösend)
„Ich bin ein kompetenter Reviewer“	„Vor mir liegt ein Text klarer als das, was ich schreiben würde“
„Ich gehöre zu denen, die kritisch denken“	„Hier denkt offenbar jemand klarer als ich“
„KI macht Menschen dümmer“	„Aber dieser Text wirkt nicht dumm, sondern klüger als üblich“

Die Dissonanz ist unangenehm. Es gibt zwei Wege, sie aufzulösen:

Weg 1: Inhaltliche Auseinandersetzung (anstrengend).

Die eigene Position überdenken; anerkennen, dass der andere etwas Gutes geleistet hat; eigene Standards nachjustieren; bei Bedarf die eigene Position revidieren.

Weg 2: Quellenabwertung (bequem).

Den Text als nicht-authentisch markieren – „das ist ja gar nicht von ihm, das ist KI“. Die Selbstwahrnehmung bleibt intakt. Keine eigene Revision nötig.

Der KI-Detektor liefert die *technische Rechtfertigung* für Weg 2. Er erlaubt es, den unbequemen Text zu disqualifizieren, ohne sich mit ihm auseinanderzusetzen zu müssen. Der Score wirkt wissenschaftlich, objektiv, neutral – und besorgt genau das, was der Reviewer braucht, um seine Dissonanz aufzulösen, ohne sich selbst zu hinterfragen.

7.3 Drei Funktionen in einem

Die Dissonanz-Reduktion durch Quellenabwertung erfüllt gleichzeitig drei Funktionen:

- **Selbstwertschutz:** „Ich bin nicht weniger kompetent – der hat nur gemogelt.“
- **Anstrengungsvermeidung:** „Ich muss mich nicht damit auseinandersetzen.“
- **Soziale Positionierung:** „Ich gehöre zu den Kritischen, die KI-Mogelei erkennen.“

Alle drei Funktionen sind *billig* zu haben – ein Klick auf einen Detektor. Die ehrliche Alternative – inhaltliche Prüfung – ist *teuer*: Zeit, Konzentration, das Risiko der eigenen Revision.

7.4 Die Verschärfung durch Pseudo-Objektivität

Klassische ad-hominem-Argumente können vom Adressaten direkt zurückgewiesen werden – man kann antworten, kontextualisieren, sich wehren. KI-Detektoren haben drei zusätzliche Eigenschaften, die die Dissonanz-Reduktion noch effektiver machen:

1. **Pseudo-Objektivität:** Die Zahl wirkt wissenschaftlich, nicht persönlich. Der Reviewer kann sagen: „Ich greife Sie ja nicht an – der Algorithmus sagt das.“
2. **Verantwortungs-Auslagerung:** Niemand fühlt sich persönlich verantwortlich für das Urteil. „Der Computer hat entschieden.“
3. **Unwiderlegbarkeit:** Der Adressat kann *nicht beweisen*, dass er die KI nicht benutzt hat. Negation ist nicht beweisbar.

Diese drei Eigenschaften machen den KI-Detektor zu einem *idealen Werkzeug zur Dissonanz-Reduktion*: maximale Wirkung bei minimaler eigener Investition und minimaler Verantwortung.

7.5 Eine bittere Pointe

Daraus folgt eine paradoxe Konsequenz: Je **klarer und kompetenter** ein Text ist, desto **größer die Dissonanz**

für einen weniger souveränen Leser – und desto **stärker das Motiv**, den Text als KI abzustempeln. Die Detektoren bestrafen also genau die Kompetenz, die sie zu schützen vorgeben. Nicht zufällig, sondern aus psychologischer Funktion.

8 Die ganze Familie rhetorischer Manipulations-Muster

Die Verwandtschaft ist nicht auf den ad-hominem-Fehlschluss beschränkt. KI-Detektoren reproduzieren tatsächlich *eine ganze Familie* klassischer Manipulations-Techniken – jeweils in technischer Form.

8.1 Tone Policing

Mensch: „Sie sind aber emotional – das kann man so nicht ernst nehmen.“

Detektor: „Sie schreiben aber sehr glatt – das kann man so nicht ernst nehmen.“

Der Stil wird zum Disqualifikator, unabhängig vom Inhalt.

8.2 Strohmann-Argument

Der *Mensch* verzerrt die Position des Gegners zu einer einfacheren, leichter zu widerlegenden Karikatur. Der *Detektor* reduziert den Text auf statistische Oberflächenmerkmale, die mit dem eigentlichen Inhalt nichts zu tun haben. In beiden Fällen wird eine vereinfachte Karikatur bewertet, nicht das Original.

8.3 Beweislastumkehr

Mensch: „Beweis mir, dass Du das selber gedacht hast.“

Detektor: „Beweise mir, dass Du keine KI benutzt hast.“

In beiden Fällen wird das Gegenteil als Default angenommen. Der Adressat muss seine Unschuld beweisen – was strukturell unmöglich ist, weil *Nicht-Existenz nicht beweisbar* ist.

8.4 Argumentum ad verecundiam

Mensch: „Das hat Professor X gesagt, also muss es stimmen.“

Detektor: „Der Algorithmus sagt 87 %, also muss es stimmen.“

Eine Autorität wird über den Inhalt gestellt. Bei KI-Detektoren ist die Autorität eine Maschine – was die Inversion verschärft.

8.5 Argumentum ad populum

Mensch: „Alle wissen doch, dass...“

Detektor: „Das sieht aus wie typischer KI-Stil, alle Modelle erkennen das Muster.“

Konsens (oder gelerntes Muster) ersetzt Argument.

8.6 Gaslighting

Mensch: „Sie überschätzen sich – das kann nicht von Ihnen kommen.“

Detektor: „Der Score zeigt: das kann nicht von Ihnen kommen.“

Dem Adressaten wird die eigene Autorenschaft abgesprochen. Er soll an sich selbst zweifeln. Das ist die destruktivste Form – sie zielt nicht auf die Aussage, sondern auf die Person selbst.

9 Die historische Linie

Die hier beschriebenen Muster sind nicht neu. Sie sind in jeder Epoche dokumentiert:

- **Antike Rhetorik:** Aristoteles hat ad-hominem-Argumente in den *Sophistischen Widerlegungen* als Fehlschlüsse beschrieben.
- **Mittelalter:** *Argumentum ad auctoritatem* (Berufung auf Autoritäten statt eigene Prüfung) als scholastische Argumentationsform.

- **Inquisition:** Verdachts-Logik – wer so denkt, ist verdächtig.
- **Totalitarismus des 20. Jahrhunderts:** „Wer so spricht, ist Feind.“
- **Gegenwart:** KI-Detektoren – „Wer so schreibt, ist nicht echt.“

Es ist immer dasselbe Muster: Wenn die inhaltliche Auseinandersetzung schwierig wird, weicht man auf die Quellenkritik aus. Die **historische Konstanz** ist die wichtigste Beobachtung dieses Dokuments – sie zeigt, dass das eigentliche Problem nicht technologisch, sondern *anthropologisch* ist.

10 Was tatsächlich helfen würde

Wenn die Detektoren nicht helfen, sondern das Problem verschärfen, was hilft dann?

Substantielles Lesen. Ein kompetenter Leser, der den Gegenstand versteht, erkennt Halluzinationen, weil er die Substanz versteht. Er braucht keinen Score. Er braucht Bereitschaft, sich auf den Inhalt einzulassen.

Reproduzierbare Verifikation. Wo der Inhalt prüfbar ist, kann er geprüft werden – durch Code, Daten, Skripte, die man selbst ausführen kann. Das ist keine Detektor-Funktion; das ist *Inhaltsfunktion*.

Provenance-Dokumentation. Drafts, Aufzeichnungen, Revisionsverlauf. Wer transparent macht, wie er gearbeitet hat, verschiebt die Frage von „Beweis, dass Du keine KI benutzt hast“ zu „hier ist der Arbeitsverlauf, schau selbst“. Die zweite Frage ist beantwortbar.

Offene Disziplin. KI bewusst als Werkzeug nutzen, nicht als Orakel. Eigene Position als die eigene markieren. Die KI-Hilfe offen ausweisen, statt sie zu verstecken.

Keiner dieser Punkte braucht einen Detektor. Alle vier brauchen *kompetente, ehrliche Menschen, die bereit sind, die Arbeit des Verstehens zu tragen*.

11 Diagnose

Die KI-Detektor-Debatte ist nicht primär technisch. Sie ist die sichtbare Spitze einer kulturellen Tendenz, die das anstrengende Geschäft des Verstehens durch die bequeme Praxis der Quellenkritik ersetzt.

In einem Satz:

Ad-hominem-Argumentation ist KI-Detektor für Menschen. KI-Detektor ist ad-hominem-Argumentation für Texte. Beides ist die Verweigerung der Sache, getarnt als Sorge um die Quelle.

Der psychologische Antrieb – kognitive Dissonanz und ihre Auflösung durch Quellenabwertung – ist seit Festinger 1956/1957 wohl dokumentiert. Die historische Konstanz des Musters reicht bis Aristoteles zurück. Die technische Vollendung in Software-Form ist neu, das zugrundeliegende Problem ist alt.

Wer einem KI-Checker mehr vertraut als seinem eigenen kritischen Urteil, hat aufgehört, ein Reviewer zu sein – und ist selbst zum Anhängsel einer Maschine geworden. Das ist der eigentliche Fehlanwender von KI.

12 Quellen

- Liang, W., Yuksekgonul, M., Mao, Y., Wu, E., Zou, J. (2023). *GPT detectors are biased against non-native English writers*. Patterns Vol. 4, Nr. 7, Artikel 100779. DOI: 10.1016/j.patter.2023.100779; arXiv:2304.02819.
- OpenAI (2023). *New AI classifier for indicating AI-written text*. Blog-Beitrag vom 31. Januar 2023,

ergänzt am 20. Juli 2023 um den Hinweis auf die Einstellung des Werkzeugs wegen niedriger Trefferquote.

- Festinger, L. (1957). *A Theory of Cognitive Dissonance*. Stanford University Press.
- Festinger, L., Riecken, H. W., Schachter, S. (1956). *When Prophecy Fails: A Social and Psychological Study of a Modern Group that Predicted the Destruction of the World*. University of Minnesota Press.
- Aristoteles. *Sophistische Widerlegungen* (Sophistikoi Elenchoi). Klassische Darstellung der rhetorischen Fehlschlüsse.
- Schopenhauer, A. *Eristische Dialektik* (postum veröffentlicht). Behandlung des *argumentum ad personam*.

Anmerkung zur Entstehung dieses Dokuments.

Der Text wurde im Mai 2026 verfasst, ausgelöst durch eine Diskussion auf der Mailingliste des *Information Physics Institute* mit Peter Austin. Die Argumentation ist mein eigenes Denken. Die sprachliche Formalisierung erfolgte mit KI-Unterstützung – in genau der Weise, die in §5 als *KI als Filter, nicht als Orakel* beschrieben ist. Eine offene Disziplin: Substanz vom Autor, Sprache mit Werkzeug-Unterstützung, Urteil beim Menschen.