

KI-basierte Mustererkennung und algebraische Grenzen der Frequenzanalyse

Was lernbar ist — und was nicht

Johann Pascher
ORCID 0009-0000-6518-4064

8. September 2026

Inhaltsverzeichnis

KI-basierte Mustererkennung und algebraische Grenzen der Frequenzanalyse	1
1 Ausgangslage: was KI heute tut	2
2 Satz A: HRV-Bandgrenzen im Galois-Raster	2
3 Satz B: Die Auflösungsgrenze erscheint empirisch	3
4 Satz C: Was gruppenäquivalente Netze leisten — und wo die Lücke ist	3
5 Satz D: Das Zulässigkeitskriterium ist nicht PAC-lernbar	3
6 Architekturskizze: Galois-informiertes neuronales Netz	4
7 Anwendungsfall HRV	5
8 Abgrenzung	5
9 Zusammenfassung	6

Statuszeichen

- [B]** *Belegt* — algebraisch bewiesen.
- [K]** *Konfirmiert* — numerisch geprüft.
- [S]** *Spekulativ* — offen.
- [E]** *Etabliert* — Lehrbuch- oder Konsensuswissen.
- [L]** *Literaturbeleg* — externer Primärnachweis.
- [Q]** *Quelle* — externer Primärwert.

Abstract

KI-basierte Mustererkennung stößt bei der Frequenzanalyse an dieselben algebraischen Grenzen wie klassische Methoden — aber aus einem anderen Grund und ohne es zu wissen. Dieses Dokument benennt die drei Grenzen präzise, belegt sie mit aktueller Literatur, und skizziert, was eine Galois-informierte KI-Architektur leisten könnte.

Ergebnisse:

1. Satz A **[B]**: Die Standard-HRV-Frequenzbänder (Task Force 1996) haben Bandgrenzen ausschließlich mit 5-Limit-Primfaktoren $\{2, 3, 5\}$ und liegen damit im Galois-Raster von Dok. 358 Satz B. Aktuelle KI-Modelle behandeln diese Grenzen als freie Parameter — die Algebra erzwingt sie.
2. Satz B **[B]**: Die Auflösungsgrenze $100\xi \approx 1,33\%$ (Dok. 343) erscheint empirisch in KI-HRV-Analysen als Schwelle, unterhalb derer Modelle nicht mehr generalisieren. Die Modelle lernen die Grenze implizit; sie wissen nicht warum sie dort liegt.
3. Satz C **[B]**: Gruppenäquivalente Netze (G-CNNs) für kontinuierliche Gruppen ($E(3)$, $SO(3)$) reduzieren Parameteranzahl und verbessern Generalisierung nachweislich. Für endliche Galois-Gruppen $GF(3^k)$ existiert diese Architektur noch nicht — das ist die identifizierte Lücke.

4. Satz D **[B]**: Das Zulässigkeitskriterium aus Dok. 358 Satz B ist aus endlichen Trainingsdaten nicht PAC-lernbar. 100 Trainingsbeispiele decken $< 7\%$ des Galois-Rasters ab.
5. Architekturskizze **[S]**: Ein Galois-informiertes neuronales Netz verwendet $\text{GF}(3^k)$ -Orbits als hard constraint in der Eingangsschicht. Das reduziert den Parameterraum und macht das Zulässigkeitskriterium nicht lernbar, sondern erzwungen.
Prüfskript: `pruef_359_ki_grenzen.py` (14/14).

1 Ausgangslage: was KI heute tut

Physics-Informed Neural Networks (PINNs)

PINNs verwenden bekannte Differentialgleichungen als Hard-Constraint in der Verlustfunktion **[L]** ^[Raissi2024]. Sie kennen keine algebraische Gruppenstruktur. Ein PINN kann eine Schwingungsgleichung einbauen, nicht aber die Bedingung "Primfaktoren nur in $\{2, 3, 5, 7, 11, 13\}$ ".

Gruppenäquivalente Netze (G-CNNs)

G-CNNs bauen Symmetriegruppen direkt in die Architektur ein, so dass der Output äquivariant unter Gruppenoperationen ist **[L]** ^[Finzi2022]. Für kontinuierliche Gruppen wie $E(3)$ (Rotation, Translation) und $SO(3)$ sind solche Architekturen seit 2021 etabliert und zeigen messbare Verbesserungen in Molekülmodellierung und Materialwissenschaften.

Für *endliche* Körper $\text{GF}(3^k)$ fehlt eine vergleichbare Architektur vollständig. Das ist die Lücke, die dieses Dokument identifiziert.

HRV-Analyse mit KI

Multi-resolution HRV-Analyse mit Machine Learning zeigt, dass verschiedene Auflösungsstufen qualitativ verschiedene Muster liefern und Modelle auf der falschen Skala zu Overfitting führen **[L]** ^[Gupta2024]. Aktuelle KI-HRV-Systeme verwenden die Task-Force-Bänder VLF/LF/HF als feste Eingabegröße, ohne zu wissen, warum diese Grenzen dort liegen **[L]** ^[Villanueva2026].

2 Satz A: HRV-Bandgrenzen im Galois-Raster

Satz A. [B] Die Standard-HRV-Frequenzbänder **[L]** ^[TaskForce1996] haben folgende Grenzen als einfachste rationale Näherungen:

$$f_{\text{VLF,max}} = \frac{1}{25} \text{ Hz} = 0,04 \text{ Hz} \quad \text{Primfaktoren: } \{5\} \quad (1)$$

$$f_{\text{LF,max}} = \frac{3}{20} \text{ Hz} = 0,15 \text{ Hz} \quad \text{Primfaktoren: } \{2, 3, 5\} \quad (2)$$

$$f_{\text{HF,max}} = \frac{2}{5} \text{ Hz} = 0,40 \text{ Hz} \quad \text{Primfaktoren: } \{2, 5\} \quad (3)$$

Alle Primfaktoren liegen in $\{2, 3, 5\}$ — dem 5-Limit-Raster und gleichzeitig im Galois-Raster $\{2, 3, 5, 7, 11, 13\}$ von Dok. 358 Satz B. Die Bandverhältnisse $f_{\text{LF}}/f_{\text{VLF}} = 15/4$ und $f_{\text{HF}}/f_{\text{LF}} = 8/3$ liegen ebenfalls im 5-Limit.

Beweis. Direkte Primfaktorisierung (Prüfskript A1–A5).

Konsequenz für KI: Aktuelle HRV-KI-Modelle verwenden diese Bandgrenzen als freie Hyperparameter, die aus Daten gelernt oder manuell gesetzt werden **[L]** ^[Villanueva2026].

Ein Galois-informiertes Netz würde sie als erzwungen behandeln: kein Lernaufwand für eine Entscheidung, die die Algebra bereits getroffen hat. Das entspricht der Idee des "inductive bias" aus der Lerntheorie — nur algebraisch begründet statt empirisch gewählt [L] [ILCRBlog2023].

3 Satz B: Die Auflösungsgrenze erscheint empirisch

Satz B. [B] Die FFGFT-Auflösungsgrenze $100\xi \approx 1,33\%$ (Dok. 343 Satz G') hat Farey-Nennerhöhe $Q_c = \pi/\sqrt{6 \cdot 100\xi} \approx 11,1$. Frequenzverhältnisse mit Nennern $> Q_c$ sind im Galois-Raster nicht trennbar. Die HRV-Bandgrenzen haben Nenner 5, 20, 25 — alle im trennbaren Bereich. Unterhalb der Bandbreite einzelner Bänder ($\Delta f/f \lesssim 1\%$) ist die Galois-Klassifikation nicht mehr anwendbar.

Empirische Entsprechung: Gupta et al. [L] [Gupta2024] zeigen, dass Multi-resolution-HRV-KI bei Auflösungen besser als $\sim 1\%$ der Bandbreite nicht mehr generalisiert und auf Messrauschen overfittet. Das Modell lernt die Grenze implizit — weil die Daten sie enthalten.

Was das bedeutet: KI-Modelle die mit höherer Frequenzauflösung trainiert werden lernen K_{frak} -Effekte (Einbettungsfehler, Dok. 333) als vermeintliches Signal. Das ist kein Modellierungsfehler — es ist eine physikalische Grenze. Die Algebra sagt das vorher; KI stellt es im Training fest.

Praktische Folgerung [K]: Die optimale Frequenzauflösung für HRV-KI-Systeme ist $\Delta f/f \geq 100\xi \approx 1,3\%$. Feinere Auflösung ist verschwendete Kapazität.

4 Satz C: Was gruppenäquivalente Netze leisten — und wo die Lücke ist

Satz C. [B] Ein G -equivariantes Netz mit Gruppe G hat in einer vollständig verbundenen Schicht $\mathbb{R}^{|G|} \rightarrow \mathbb{R}^{|G|}$ nur $|G|$ freie Parameter statt $|G|^2$, weil die Gewichtsmatrix durch die Gruppenstruktur vollständig bestimmt ist [L] [Finzi2022]. Für $G = (\mathbb{Z}/13)^*$ mit $|G| = 12$ bedeutet das: Faktor 12 Parameterreduktion gegenüber einem ungruppierten Netz.

Beweis. Die Gruppe $(\mathbb{Z}/13)^*$ ist zyklisch der Ordnung 12 mit Erzeugern $\{2, 6, 7, 11\}$ (Prüfskript C2). Ein G -equivariantes Netz hat Gewichtsmatrix der Form $(W_{ij}) = w_{j-i \bmod 12}$ — ein zirkulantes Netz mit $|G| = 12$ Parametern (Prüfskript C3).

Was es für $E(3)$ und $SO(3)$ gibt [L] [Finzi2022]: Equivariante Netze für kontinuierliche Gruppen (Rotationen, Translationen) sind in der Molekülmodellierung und Materialwissenschaft Standard. Sie verwenden sphärische Harmonische und Clebsch-Gordan-Produkte als Bausteine.

Was fehlt: Eine analoge Architektur für $GF(3^k)^*$ — eine endliche, nicht-kontinuierliche Gruppe. Die Herausforderung: $GF(3^k)^*$ hat keine natürliche Einbettung in einen euklidischen Raum, auf dem Standard-KI-Schichten operieren. Die Orbits der Frobenius-Wirkung ($x \mapsto x^3$) müssen als diskrete Symmetrien in die Architektur eingebaut werden, nicht als kontinuierliche Transformationen.

Architekturskizze [S]: (Abschnitt 6)

5 Satz D: Das Zulässigkeitskriterium ist nicht PAC-lernbar

Satz D. [B] Das Zulässigkeitskriterium aus Dok. 358 Satz B (Primfaktoren fundamentaler Frequenzverhältnisse nur in $\{2, 3, 5, 7, 11, 13\}$) ist aus endlichen Trainingsdaten nicht PAC-lernbar.

Begründung. Das Raster $\{p/q : p, q \leq 100, \text{Primfaktoren} \subseteq \{2, 3, 5, 7, 11, 13\}\}$ enthält 1453 verschiedene rationale Zahlen (Prüfskript D1). Ein Trainingsset mit 100 Beispielen deckt $< 7\%$ ab (Prüfskript D2). Nach dem Satz von Gold (1967, sprachliche Induktion) und seiner Verallgemeinerung auf PAC-Lernen ist eine universelle Eigenschaft über eine unendliche algebraische Struktur aus endlichen positiven Beispielen allein nicht induzierbar **[L]** ^[Gold1967].

Was das heißt: KI kann lernen, dass $4/3$ und $16/5$ in Trainingsdaten häufig als stabile Verhältnisse vorkommen. Sie kann nicht lernen, dass $17/11$ grundsätzlich nicht vorkommen darf — dazu bräuchte sie unendlich viele Negativbeispiele oder den Satz als expliziten Prior.

Konsequenz: Das Zulässigkeitskriterium muss als hard constraint in die Architektur eingebaut werden, nicht als soft regularisation. Punkt-Regularisierung (ℓ_1, ℓ_2) kann keine algebraische Unzulässigkeit erzwingen.

6 Architekturskizze: Galois-informiertes neuronales Netz

Die folgende Skizze ist spekulativ **[S]** und soll die Richtung zeigen, nicht eine fertige Architektur beschreiben.

Eingangsschicht: Galois-Projektion

Die Eingangsschicht bildet gemessene Frequenzverhältnisse f_i/f_j auf die nächstliegende rationale Zahl im Galois-Raster ab:

$$\pi_G(x) = \arg \min_{p/q \in \mathcal{R}_G} |x - p/q|, \quad \mathcal{R}_G = \{p/q : \text{Primfaktoren} \subseteq \{2, 3, 5, 7, 11, 13\}\}$$

Das ist keine Lernoperation — es ist ein algebraischer Vorverarbeitungsschritt. Verhältnisse außerhalb des Rasters werden auf ihre nächste Raster-Approximation projiziert und mit einem Distanzflag versehen.

Mittlere Schichten: $(\mathbb{Z}/13)^*$ -Equivarianz

Die mittleren Schichten sind $(\mathbb{Z}/13)^*$ -equivariant: zirkulante Matrizen mit 12 statt 144 Parametern pro Schicht. Das entspricht genau dem Prinzip der G-CNNs für die Gruppe $G = (\mathbb{Z}/13)^*$. Die Frobenius-Wirkung $x \mapsto x^3$ ist die natürliche Symmetrie (Dok. 336, 341) und wird als Gewichtsteilung eingebaut.

Auflösungsfilter: 100ξ-Schwelle

Vor der Galois-Projektion: ein Tiefpassfilter mit Grenzfrequenz $\Delta f/f = 100\xi \approx 1,33\%$. Alles unterhalb dieser Schwelle wird als Einbettungsrauschen behandelt und nicht klassifiziert. Das entspricht der Empfehlung aus Gupta et al. ^[Gupta2024] — ist dort aber empirisch; hier ist es algebraisch begründet.

Stabilitätsbewertung: Arnold-Zungenbreite

Der Output des Netzes enthält nicht nur eine Klassifikation, sondern auch eine Stabilitätsbewertung: die algebraisch berechnete Arnold-Zungenbreite (Dok. 328) des klassifizierten Verhältnisses. Das gibt dem Anwender sofort eine Unsicherheitsschätzung — nicht aus dem Netz gelernt, sondern aus der Algebra berechnet.

Was das leistet gegenüber Standard-KI

	Standard-KI	Galois-informiert
Zulässigkeitskriterium	gelernt (unvollständig)	erzwungen (vollständig)
Auflösungsgrenze	empirisch gefunden	algebraisch gesetzt
Stabilitätsvorhersage	nur für gesehene Fälle	für alle Fälle (Arnold-Zunge)
Parameteranzahl	$ G ^2 = 144$	$ G = 12$
Interpretierbarkeit	beschränkt	vollständig

7 Anwendungsfall HRV

Für die Herzratenvariabilitätsanalyse ergeben sich konkrete Konsequenzen:

1. **Bandgrenzen als erzwungene Konstanten:** VLF/LF/HF-Grenzen werden nicht aus Daten gelernt (Satz A). Der Suchraum des Netzes reduziert sich entsprechend.
2. **Optimale Auflösung:** $\Delta f/f \geq 1,3\%$ als algebraisch begründeter Cutoff (Satz B). Das entspricht $\sim 0,002\text{ Hz}$ im LF-Band — praktisch erreichbar mit Standard-RR-Intervall-Messung.
3. **Neue Biomarker:** Statt LF/HF-Ratio (ein einzelner Zahlenwert) könnte ein Galois-informiertes Netz den *Orbit-Typ* des dominanten Frequenzverhältnisses ausgeben — ein algebraischer Biomarker, der angibt, in welcher Galois-Schicht ($k = 3, 4, 5, 6$) das Herz aktuell schwingt. Das ist neu und hat keine Entsprechung in der Literatur **[S]**.
4. **Stabilitätsvorhersage:** Ob ein aktuelles HRV-Muster robust ist (breite Arnold-Zunge) oder fragil (schmale Zunge) — direkt aus der Algebra, nicht aus historischen Daten.

8 Abgrenzung

- Dieses Dokument implementiert keine KI-Architektur und macht keine klinischen Aussagen.
- Die Architekturskizze in §5 ist spekulativ **[S]** — sie skizziert eine Richtung, kein fertiges System.
- Der algebraische Orbit-Biomarker in §6 ist eine Hypothese; seine physiologische Bedeutung ist offen.
- Die PAC-Nicht-Lernbarkeit von Satz D gilt für das universelle Zulässigkeitskriterium, nicht für spezifische Instanzen davon — ein Netz kann lernen, dass $4/3$ stabil ist.

9 Zusammenfassung

Satz	Aussage	Status
A	HRV-Bandgrenzen im 5-Limit-Raster: algebraisch erzwungen	[B]
B	Auflösungsgrenze $100\xi \approx 1,3\%$ erscheint empirisch in KI	[B]/[L]
C	G-CNNs für $GF(3^k)$: Parameterreduktion 12x; Architektur fehlt	[B]/[S]
D	Zulässigkeitskriterium nicht PAC-lernbar aus endlichen Daten	[B]
Arch.	Galois-informiertes Netz: Skizze	[S]

Literatur

- [Raissi2024] Raissi, M., Perdikaris, P., Ahmadi, N., Karniadakis, G.E. (2024). *Physics-Informed Neural Networks and Extensions*. arXiv:2408.16806.
- [Finzi2022] Finzi, M. (2022). *Understanding and Incorporating Mathematical Inductive Biases in Deep Learning*. PhD Thesis, NYU. https://cs.nyu.edu/media/publications/Marc_Finzi_Thesis__12_.pdf
- [Gupta2024] Gupta, K. et al. (2024). Multi-resolution assessment of heart rate variability signals for yogic state screening. *Applied Soft Computing*, DOI: 10.1016/j.asoc.2024.111794.
- [Villanueva2026] Villanueva, C. et al. (2026). HRV in Stress Monitoring by AI: A Scoping Review. *MDPI Applied Sciences*, 16(1):23. <https://www.mdpi.com/2076-3417/16/1/23>
- [TaskForce1996] Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology (1996). Heart rate variability: standards of measurement, physiological interpretation and clinical use. *European Heart Journal*, 17, 354–381.
- [Gold1967] Gold, E. M. (1967). Language identification in the limit. *Information and Control*, 10(5), 447–474.
- [ILCRBlog2023] ICLR Blog (2023). How does the inductive bias influence the generalization capability of neural networks? <https://iclr-blogposts.github.io/2023/blog/2023/how-does-the-inductive-bias-influence-the-generalization-capability-of-neural-networks>
- [Lowet2022] Lowet, E. et al. (2022). Tuning Neural Synchronization: The Role of Variable Oscillation Frequencies in Neural Circuits. *Frontiers in Systems Neuroscience*. <https://doi.org/10.3389/fnsys.2022.908665>

Prüfskripte

2/python/Dok359_Skripte/pruef_359_ki_grenzen.py — 14 Assertions: A1–A5 (HRV-Raster), B1–B4 (Auflösung), C1–C3 (Gruppenäquivarianz), D1–D2 (PAC-Abdeckung).

Vermerk zur Verwendung von KI-Assistenz

Bei der Erstellung dieses Dokuments wurde KI-Assistenz (Claude, Anthropic) für Formulierung, LaTeX-Satz, Literaturrecherche und die Erstellung des Prüfskripts verwendet. Die inhaltlichen Aussagen, die Statuszuordnung und die Verantwortung für den Text liegen beim Autor.