KI-basierte Mustererkennung und algebraische Grenzen der Frequenzanalyse

Was lernbar ist — und was nicht

Johann Pascher
ORCID 0009-0000-6518-4064

8. September 2026

Inhaltsverzeichnis

KI-basierte Mustererkennung und algebraische Grenzen der Frequenzanalyse 1

1 Ausgangslage: was KI heute tut 2
2 Satz A: HRV-Bandgrenzen im Galois-Raster 2
3 Satz B: Auflösungsgrenze und Farey-Höhe 3
4 Satz C: Was gruppenäquivariante Netze leisten — und wo die Lücke ist 3
5 Satz D: Lernbarkeit hängt an der Hypothesenklasse 3
6 Architekturskizze: Galois-informiertes neuronales Netz 4
7 Anwendungsfall HRV 5
8 Abgrenzung 5
9 Zusammenfassung 6

Statuszeichen

[B] *Belegt* — algebraisch bewiesen.
[K] *Konfirmiert* — numerisch geprüft.
[S] *Spekulativ* — offen.
[E] *Etabliert* — Lehrbuch- oder Konsensuswissen.
[L] *Literaturbeleg* — externer Primärnachweis.
[Q] *Quelle* — externer Primärwert.

Abstract

KI-basierte Mustererkennung stößt bei der Frequenzanalyse an dieselben algebraischen Grenzen wie klassische Methoden — aber aus einem anderen Grund und ohne es zu wissen. Dieses Dokument benennt die drei Grenzen präzise, belegt sie mit aktueller Literatur, und skizziert, was eine Galois-informierte KI-Architektur leisten könnte.

Ergebnisse:

1. Satz A **[B]**: Die Standard-HRV-Frequenzbänder (Task Force 1996) haben Bandgrenzen ausschließlich mit 5-Limit-Primfaktoren $\{2, 3, 5\}$ und liegen damit im Galois-Raster von Dok. 358 Satz B. Sie sind mit dem Raster verträglich, aber nicht durch es festgelegt: Gerundete Dezimalwerte liegen fast immer im 5-Limit (Dok. 360).
2. Satz B **[B]**: Die Auflösungsgrenze $100\xi \approx 1{,}33\,\%$ (Dok. 343) hat die Farey-Höhe $Q_c \approx 11{,}1$. Eine Klassifikation mit dieser Toleranz verlangt eine Frequenzauflösung $\Delta f / f \leq 100\xi$.
3. Satz C **[B]**: Gruppenäquivariante Netze (G-CNNs) für kontinuierliche Gruppen (E(3), SO(3)) reduzieren Parameteranzahl und verbessern Generalisierung nachweislich. Für endliche Galois-Gruppen GF(3^k) existiert diese Architektur noch nicht — das ist die identifizierte Lücke.

4. Satz D **[B]**: Ob das Zulässigkeitskriterium aus Dok. 358 Satz B lernbar ist, entscheidet die Hypothesenklasse, nicht die Datenmenge. Ohne Strukturannahme verlangt die PAC-Schranke rund 84 000 markierte Beispiele; mit der Strukturannahme „Primfaktoren aus einer festen Menge“ genügen höchstens 407, und aus positiven Beispielen allein wird die Primzahlmenge $\{2, 3, 5, 7, 11, 13\}$ schon nach 30 Beispielen sicher erkannt.
5. Architekturskizze **[S]**: Ein Galois-informiertes neuronales Netz verwendet GF(3^k)-Orbits als hard constraint in der Eingangsschicht. Das reduziert den Parameterraum und macht das Zulässigkeitskriterium nicht lernbar, sondern erzwungen.
   Prüfskript: `pruef_359_ki_grenzen.py` (18/18).

1 Ausgangslage: was KI heute tut

Physics-Informed Neural Networks (PINNs)

PINNs verwenden bekannte Differentialgleichungen als Hard-Constraint in der Verlustfunktion **[L]** [Raissi2024]. Sie kennen keine algebraische Gruppenstruktur. Ein PINN kann eine Schwingungsgleichung einbauen, nicht aber die Bedingung “Primfaktoren nur in $\{2, 3, 5, 7, 11, 13\}$”.

Gruppenäquivariante Netze (G-CNNs)

G-CNNs bauen Symmetriegruppen direkt in die Architektur ein, so dass der Output äquivariant unter Gruppenoperationen ist **[L]** [Finzi2022]. Für kontinuierliche Gruppen wie E(3) (Rotation, Translation) und SO(3) sind solche Architekturen seit 2021 etabliert und zeigen messbare Verbesserungen in Molekülmodellierung und Materialwissenschaften.

Für *endliche* Körper GF(3^k) fehlt eine vergleichbare Architektur vollständig. Das ist die Lücke, die dieses Dokument identifiziert.

HRV-Analyse mit KI

Multi-resolution-HRV-Analyse mit Machine Learning zeigt, dass verschiedene Auflösungsstufen unterschiedliche Merkmale liefern **[L]** [Gupta2024]. Aktuelle KI-HRV-Systeme verwenden die Task-Force-Bänder VLF/LF/HF als feste Eingabegröße, ohne zu wissen, warum diese Grenzen dort liegen **[L]** [Villanueva2026].

2 Satz A: HRV-Bandgrenzen im Galois-Raster

Satz A. [B] Die Standard-HRV-Frequenzbänder **[L]** [TaskForce1996] haben folgende Grenzen als einfachste rationale Näherungen:

$$f_{\mathrm{VLF,max}} = \tfrac{1}{25}\,\mathrm{Hz} = 0{,}04\,\mathrm{Hz} \qquad \text{Primfaktoren: } \{5\} \tag{1}$$

$$f_{\mathrm{LF,max}} = \tfrac{3}{20}\,\mathrm{Hz} = 0{,}15\,\mathrm{Hz} \qquad \text{Primfaktoren: } \{2, 3, 5\} \tag{2}$$

$$f_{\mathrm{HF,max}} = \tfrac{2}{5}\,\mathrm{Hz} = 0{,}40\,\mathrm{Hz} \qquad \text{Primfaktoren: } \{2, 5\} \tag{3}$$

Alle Primfaktoren liegen in $\{2, 3, 5\}$ — dem 5-Limit-Raster und gleichzeitig im Galois-Raster $\{2, 3, 5, 7, 11, 13\}$ von Dok. 358 Satz B. Die Bandverhältnisse $f_{\mathrm{LF}}/f_{\mathrm{VLF}} = 15/4$ und $f_{\mathrm{HF}}/f_{\mathrm{LF}} = 8/3$ liegen ebenfalls im 5-Limit.

Beweis. Direkte Primfaktorisierung (Prüfskript A1–A5).

Konsequenz für KI: Aktuelle HRV-KI-Modelle verwenden diese Bandgrenzen als freie Hyperparameter, die aus Daten gelernt oder manuell gesetzt werden **[L]** [Villanueva2026]. Ein Galois-informiertes Netz könnte sie als feste Konstanten übernehmen. Das ist eine Setzung, keine algebraische Notwendigkeit: 8 von 9 Zahlen mit einer gültigen Ziffer und ein Drittel aller zweistelligen Dezimalwerte liegen im 5-Limit, und in rad/s sind die Grenzen irrational (Dok. 360). Als "inductive bias" im Sinne der Lerntheorie **[L]** [ILCRBlog2023] ist die Übernahme zulässig, aber nicht algebraisch begründet.

3 Satz B: Auflösungsgrenze und Farey-Höhe

> **Satz B. [B]** Die FFGFT-Auflösungsgrenze $100\xi \approx 1{,}33\,\%$ (Dok. 343 Satz G′) hat Farey-Nennerhöhe $Q_c = \pi/\sqrt{6 \cdot 100\xi} \approx 11{,}1$. Frequenzverhältnisse mit Nennern $> Q_c$ sind im Galois-Raster nicht trennbar. Die HRV-Bandgrenzen haben Nenner 5, 20, 25 — alle im trennbaren Bereich. Eine Klassifikation mit der Toleranz 100ξ ist nur sinnvoll, wenn die Frequenzauflösung $\Delta f/f \leq 100\xi$ erfüllt.

Praktische Folgerung [K]: Mit $\Delta f = 1/T_w$ für die Fensterlänge T_w (bei Welch die Segmentlänge) folgt $T_w \geq 1/(100\xi f)$, also 12,5 min bei 0,10 Hz und 15 min bei 0,083 Hz (Dok. 360). Kürzere Fenster können Rasterelemente nicht unterscheiden. Ob die Schwelle in KI-HRV-Analysen empirisch auftritt, ist nicht belegt **[S]**.

4 Satz C: Was gruppenäquivariante Netze leisten — und wo die Lücke ist

> **Satz C. [B]** Ein G-equivariantes Netz mit Gruppe G hat in einer vollständig verbundenen Schicht $\mathbb{R}^{|G|} \to \mathbb{R}^{|G|}$ nur $|G|$ freie Parameter statt $|G|^2$, weil die Gewichtsmatrix durch die Gruppenstruktur vollständig bestimmt ist **[L]** [Finzi2022]. Für $G = (\mathbb{Z}/13)^*$ mit $|G| = 12$ bedeutet das: Faktor 12 Parameterreduktion gegenüber einem ungruppierten Netz.

Beweis. Die Gruppe $(\mathbb{Z}/13)^*$ ist zyklisch der Ordnung 12 mit Erzeugern $\{2, 6, 7, 11\}$ (Prüfskript C2). Ein G-equivariantes Netz hat Gewichtsmatrix der Form $(W_{ij}) = w_{j-i \bmod 12}$ — ein zirkulantes Netz mit $|G| = 12$ Parametern (Prüfskript C3).

Was es für E(3) und SO(3) gibt [L] [Finzi2022]: Equivariante Netze für kontinuierliche Gruppen (Rotationen, Translationen) sind in der Molekülmodellierung und Materialwissenschaft Standard. Sie verwenden sphärische Harmonische und Clebsch-Gordan-Produkte als Bausteine.

Was fehlt: Eine analoge Architektur für GF$(3^k)^*$ — eine endliche, nicht-kontinuierliche Gruppe. Die Herausforderung: GF$(3^k)^*$ hat keine natürliche Einbettung in einen euklidischen Raum, auf dem Standard-KI-Schichten operieren. Die Orbits der Frobenius-Wirkung ($x \mapsto x^3$) müssen als diskrete Symmetrien in die Architektur eingebaut werden, nicht als kontinuierliche Transformationen.

Architekturskizze [S]: (Abschnitt 6)

5 Satz D: Lernbarkeit hängt an der Hypothesenklasse

> **Satz D. [B]** Auf dem beschränkten Raster der gekürzten Brüche p/q mit $p, q \leq 100$ ist das Zulässigkeitskriterium aus Dok. 358 Satz B (Primfaktoren nur in

$\{2, 3, 5, 7, 11, 13\}$) lernbar. Wie viele Beispiele dafür nötig sind, entscheidet die Hypothesenklasse, also das Vorwissen, das ein lernendes System mitbringt, und nicht die Datenmenge allein.

Begründung. Das Raster umfasst 6087 gekürzte Brüche, davon sind 1453 zulässig (Prüfskripte D1, D3). Hundert Beispiele decken weniger als $7\,\%$ der zulässigen Verhältnisse ab (D2). Für eine endliche Hypothesenklasse $\mathscr{H}$ genügen im realisierbaren Fall $m \geq (\ln|\mathscr{H}| + \ln(1/\delta))/\varepsilon$ markierte Beispiele, um mit Wahrscheinlichkeit $1-\delta$ einen Fehler unter ε zu erreichen **[L]** [ShalevShwartz2014]. Mit $\varepsilon = \delta = 5\,\%$ ergibt das zwei sehr verschiedene Fälle.

Ohne Strukturannahme, wenn also jede Teilmenge der 6087 Brüche als Kriterium in Frage kommt, ist $|\mathscr{H}| = 2^{6087}$ und die VC-Dimension gleich 6087. Die Schranke verlangt rund 84 000 markierte Beispiele (D4), und aus positiven Beispielen allein ist das Kriterium nicht zu gewinnen, weil jedes ungesehene Verhältnis ebenso gut zulässig sein könnte. Das ist die Lage eines generischen Netzes ohne eingebautes Vorwissen.

Mit der Strukturannahme „zulässig sind genau die Brüche, deren Primfaktoren in einer festen Menge P liegen“, wobei P eine Teilmenge der 25 Primzahlen bis 100 ist, gilt $|\mathscr{H}| = 2^{25}$, und es genügen höchstens 407 Beispiele (D5). In dieser Klasse lernt sogar ein Verfahren, das nur positive Beispiele sieht: Es nimmt als P die kleinste Primzahlmenge, die alle gesehenen Beispiele erklärt. Bei zufällig gezogenen zulässigen Verhältnissen erkennt es $\{2, 3, 5, 7, 11, 13\}$ nach 10 Beispielen in $94{,}6\,\%$ und nach 30 Beispielen in allen von 1000 Durchläufen (D6). Ein solches System schließt $17/11$ aus, ohne je ein Negativbeispiel gesehen zu haben, weil die 17 in keinem Beispiel auftritt.

Der Satz von Gold **[L]** [Gold1967] betrifft die Identifikation einer Sprache im Grenzwert aus unendlichen Folgen positiver Beispiele; er greift erst, wenn die Hypothesenklasse unbeschränkt ist, und trägt für das beschränkte Raster keine Nicht-Lernbarkeit.

Was das heißt: Das Wissen, dass nur die Primzahlen bis 13 vorkommen, steckt nicht in der Menge der Trainingsdaten, sondern in der Form der Hypothesen. Ein Netz, dem diese Form fehlt, braucht um mehr als zwei Größenordnungen mehr markierte Beispiele, und mit Messrauschen oberhalb der Auflösungsgrenze aus Satz B gewinnt es die fehlende Information gar nicht.

Konsequenz: Das Zulässigkeitskriterium gehört als Strukturvorgabe in die Architektur, nicht als nachträgliche Regularisierung. Punkt-Regularisierung (ℓ_1, ℓ_2) bevorzugt kleine Gewichte, aber keine Primfaktormenge, und erzwingt deshalb keine algebraische Unzulässigkeit.

6 Architekturskizze: Galois-informiertes neuronales Netz

Die folgende Skizze ist spekulativ **[S]** und soll die Richtung zeigen, nicht eine fertige Architektur beschreiben.

Eingangsschicht: Galois-Projektion

Die Eingangsschicht bildet gemessene Frequenzverhältnisse f_i/f_j auf die nächstliegende rationale Zahl im Galois-Raster ab:

$$\pi_G(x) = \operatorname*{arg\,min}_{p/q \in \mathscr{R}_G} |x - p/q|, \quad \mathscr{R}_G = \{p/q : \text{Primfaktoren} \subseteq \{2, 3, 5, 7, 11, 13\}\}$$

Das ist keine Lernoperation — es ist ein algebraischer Vorverarbeitungsschritt. Verhältnisse außerhalb des Rasters werden auf ihre nächste Raster-Approximation projiziert und mit einem Distanzflag versehen.

Mittlere Schichten: $(\mathbb{Z}/13)^*$-Equivarianz

Die mittleren Schichten sind $(\mathbb{Z}/13)^*$-equivariant: zirkulante Matrizen mit 12 statt 144 Parametern pro Schicht. Das entspricht genau dem Prinzip der G-CNNs für die Gruppe $G = (\mathbb{Z}/13)^*$. Die Frobenius-Wirkung $x \mapsto x^3$ ist die natürliche Symmetrie (Dok. 336, 341) und wird als Gewichtsteilung eingebaut.

Auflösungsfilter: 100ξ-Schwelle

Vor der Galois-Projektion: ein Tiefpassfilter mit Grenzfrequenz $\Delta f/f = 100\xi \approx 1{,}33\,\%$. Alles unterhalb dieser Schwelle wird als Einbettungsrauschen behandelt und nicht klassifiziert. Die Schwelle ist eine Setzung der FFGFT; eine empirische Entsprechung in HRV-Daten ist nicht belegt (Dok. 360).

Stabilitätsbewertung: Arnold-Zungenbreite

Der Output des Netzes enthält nicht nur eine Klassifikation, sondern auch eine Stabilitätsbewertung: die algebraisch berechnete Arnold-Zungenbreite (Dok. 328) des klassifizierten Verhältnisses. Das gibt dem Anwender sofort eine Unsicherheitsschätzung — nicht aus dem Netz gelernt, sondern aus der Algebra berechnet.

Was das leistet gegenüber Standard-KI

	Standard-KI	Galois-informiert
Zulässigkeitskriterium	gelernt (unvollständig)	erzwungen (vollständig)
Auflösungsgrenze	nicht vorgesehen	algebraisch gesetzt
Stabilitätsvorhersage	nur für gesehene Fälle	für alle Fälle (Arnold-Zunge)
Parameteranzahl	$\lvert G\rvert^2 = 144$	$\lvert G\rvert = 12$
Interpretierbarkeit	beschränkt	vollständig

7 Anwendungsfall HRV

Für die Herzratenvariabilitätsanalyse ergeben sich konkrete Konsequenzen:

1. **Bandgrenzen als feste Konstanten:** VLF/LF/HF-Grenzen werden nicht aus Daten gelernt (Satz A); sie sind mit dem Raster verträglich, aber eine Setzung. Der Suchraum des Netzes reduziert sich entsprechend.
2. **Erforderliche Auflösung:** $\Delta f/f \leq 1{,}33\,\%$ (Satz B), also $\approx 0{,}0013$ Hz bei 0,10 Hz und eine Fensterlänge von mindestens 12,5 min.
3. **Neue Biomarker:** Statt LF/HF-Ratio (ein einzelner Zahlenwert) könnte ein Galois-informiertes Netz den *Orbit-Typ* des dominanten Frequenzverhältnisses ausgeben — ein algebraischer Biomarker, der angibt, in welcher Galois-Schicht ($k = 3, 4, 5, 6$) das Herz aktuell schwingt. Das ist neu und hat keine Entsprechung in der Literatur **[S]**.
4. **Stabilitätsvorhersage [S]:** Ob ein aktuelles HRV-Muster robust ist (breite Arnold-Zunge) oder fragil (schmale Zunge). Die Prämisse, dass HRV-Frequenzverhältnisse auf dem Raster einrasten, ist ungeprüft; die Daten in Dok. 360 stützen sie nicht, ein prospektiver Test ist dort beschrieben.

8 Abgrenzung

- Dieses Dokument implementiert keine KI-Architektur und macht keine klinischen Aussagen.
- Die Architekturskizze in §5 ist spekulativ **[S]** — sie skizziert eine Richtung, kein fertiges System.
- Der algebraische Orbit-Biomarker in §6 ist eine Hypothese; seine physiologische Bedeutung ist offen. Die explorative Prüfung an HRV-Daten (Dok. 360) ergab einen Negativbefund.
- Satz D vergleicht Stichprobenschranken auf dem beschränkten Raster $p, q \leq 100$; über einem unbeschränkten Raster mit beliebig großen Primzahlen ist die Hypothesenklasse unendlich, und die Aussagen sind neu zu prüfen.

9 Zusammenfassung

Satz	Aussage	Status
A	HRV-Bandgrenzen im 5-Limit-Raster: verträglich, nicht festgelegt	**[B]**
B	Auflösungsgrenze $100\xi \approx 1{,}33\,\%$, $Q_c \approx 11{,}1$; Klassifikation verlangt $\Delta f/f \leq 100\xi$	**[B]**
C	G-CNNs für GF(3^k): Parameterreduktion 12x; Architektur fehlt	**[B]/[S]**
D	Lernbarkeit des Zulässigkeitskriteriums: ohne Strukturannahme ~84 000, mit Primfaktor-Struktur ≤407 Beispiele	**[B]**
Arch.	Galois-informiertes Netz: Skizze	**[S]**

Literatur

[Raissi2024] Raissi, M., Perdikaris, P., Ahmadi, N., Karniadakis, G. E. (2024). *Physics-Informed Neural Networks and Extensions.* arXiv:2408.16806.

[Finzi2022] Finzi, M. (2023). *Understanding and Incorporating Mathematical Inductive Biases in Neural Networks.* PhD Thesis, NYU. https://cs.nyu.edu/media/publications/Marc_Finzi_Thesis__12_.pdf

[Gupta2024] Gupta, K., Sinha, G. R., Bhat, R., Saoji, A. A., & Manjunath, N. K. (2024). Multi-resolution assessment of heart rate variability signals during yogic and normal breathing using machine learning modules. *Applied Soft Computing*, 164, 112020. DOI: 10.1016/j.asoc.2024.112020.

[Villanueva2026] Zimatore, G. et al. (2026). HRV in Stress Monitoring by AI: A Scoping Review. *MDPI Applied Sciences*, 16(1):23. https://www.mdpi.com/2076-3417/16/1/23

[TaskForce1996] Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology (1996). Heart rate variability: standards of measurement, physiological interpretation and clinical use. *European Heart Journal*, 17, 354–381.

[Gold1967] Gold, E. M. (1967). Language identification in the limit. *Information and Control*, 10(5), 447–474.

[ShalevShwartz2014] Shalev-Shwartz, S., & Ben-David, S. (2014). *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press.

[ILCRBlog2023] ICLR Blog (2023). How does the inductive bias influence the generalization capability of neural networks? https://iclr-blogposts.github.io/2023/blog/2023/how-does-the-inductive-bias-influence-the-generalization-capability-of-neural-networks

[Lowet2022] Lowet, E. et al. (2022). Tuning Neural Synchronization: The Role of Variable Oscillation Frequencies in Neural Circuits. *Frontiers in Systems Neuroscience*. https://doi.org/10.3389/fnsys.2022.908665

Prüfskripte

`2/python/Dok359_Skripte/pruef_359_ki_grenzen.py` — 18 Assertions: A1–A5 (HRV-Raster), B1–B4 (Auflösung), C1–C3 (Gruppenäquivarianz), D1–D6 (Raster, Abdeckung, PAC-Schranken, Lernen aus positiven Beispielen).

Vermerk zur Verwendung von KI-Assistenz

Bei der Erstellung dieses Dokuments wurde KI-Assistenz (Claude, Anthropic) für Formulierung, LaTeX-Satz, Literaturrecherche und die Erstellung des Prüfskripts verwendet. Die inhaltlichen Aussagen, die Statuszuordnung und die Verantwortung für den Text liegen beim Autor.