Rauschgrenze und lernende Systeme

Fragen und Antworten zu Mustererkennung, Sprache und Zahlen

Johann Pascher
ORCID 0009-0000-6518-4064

13. Oktober 2026

Inhaltsverzeichnis

Rauschgrenze und lernende Systeme 2

1 Die Rauschgrenze im Korpus 1

2 Stoßen neuronale Netze und Sprachmodelle an dieselbe Grenze? 1

3 Warum bilden Sprachmodelle trotzdem lesbare Sätze? 2

4 Müssten harmonische Muster nicht so dicht sein wie Grammatik? 2

5 Der Nulltest 2

6 Sprache ändert sich laufend, und trotzdem funktioniert es 3

7 Warum verzeiht Sprache Fehler und Zahlen nicht? 4

8 Schöpfen KI-Modelle aus einem fertigen Rahmenwerk? 4

9 Woher kommen die Regeln eines KI-Assistenten? 5

10 Wie entsteht nach einer Fehlermeldung der nächste Schritt? 5

11 Zufall und Wahrscheinlichkeit 6

12 Fließt die Rauschgrenze in die Gewichte ein? 6

13 Der gemeinsame Kern in einem Bild 7

Werkzeug und Methode 7

Rauschgrenze und lernende Systeme

Zusammenfassung

Der Korpus kennt eine Rauschgrenze: Ab einer bestimmten Messtoleranz sind harmonische Zusammenhänge nicht mehr von Zufall zu unterscheiden (Dok. 343, Satz G′). Dieses Dokument geht in Frage und Antwort der Frage nach, ob neuronale Netze und Sprachmodelle an dieselbe Grenze stoßen, warum sie trotzdem fast immer lesbare Sätze bilden, warum Sprache Fehler verzeiht und Zahlen nicht, und welche Rolle Wahrscheinlichkeit und die Gewichte eines Netzes dabei spielen. Ein Nulltest mit vollständiger symbolischer Suche über rund 23 Millionen Ausdrücke zeigt, dass die dimensionslosen Messgrößen der Grundform allein keine harmonische Struktur über Zufallsniveau tragen, und dass selbst eine echte Regel wie die Balmer-Serie aus wenigen Beispielen nur mit der passenden, engen Vorgabe sichtbar wird. Der gemeinsame Kern aller Antworten: Diskrete Struktur ist fehlertolerant, die Rauschgrenze sitzt am Übergang vom Diskreten zum Kontinuum, und Struktur, die die Daten nicht hergeben, muss vorgegeben und dann geprüft werden.

Statusmarkierungen

[B] Algebraisch oder informationstheoretisch bewiesen.
[K] Numerisch bestätigt (Prüfskript).
[S] Setzung, offen oder Einordnung ohne eigene Rechnung.
[X] Durch die Rechnung ausgeschlossen.
[Q] Aus der Literatur übernommen, mit Quelle.

Das Dokument ist als Folge von Fragen und Antworten aufgebaut. Die Fragen sind in der Reihenfolge belassen, in der sie sich auseinander ergeben; jede Antwort steht für sich. Abschnitt 13 fasst den gemeinsamen Kern in einem Bild zusammen.

1 Die Rauschgrenze im Korpus

Frage. Was ist mit der Rauschgrenze gemeint?

Antwort. Ein gemessenes Verhältnis ist nur bis auf eine Toleranz ε bekannt. Je größer der zugelassene Nenner, desto dichter liegen die Brüche; ab der Farey-Höhe

$$Q_c = \frac{\pi}{\sqrt{6}\,\varepsilon}$$

liegen im Toleranzfenster so viele Brüche, dass ein echtes Verhältnis nicht mehr von einem zufälligen zu trennen ist (Dok. 343, Satz G′). Bei $\varepsilon = 1{,}05\,\%$, der Größe der fraktalen Korrektur, ist $Q_c \approx 12{,}5$; bei $\varepsilon = 100\,\xi \approx 1{,}33\,\%$ ist $Q_c \approx 11{,}1$ (Dok. 359, Satz B) **[K]**. Harmonische Zusammenhänge mit kleinen Nennern bleiben sichtbar, feinere gehen im Rauschen unter. Die Grenze ist eine Eigenschaft der Daten, nicht des Verfahrens: Was im Signal nicht enthalten ist, holt keine Analyse zurück, weder eine Fourier-Analyse noch eine Autokorrelation **[B]**.

2 Stoßen neuronale Netze und Sprachmodelle an dieselbe Grenze?

Frage. Müssten neuronale Netze und Sprachmodelle bei der Mustererkennung nicht ebenfalls an diese Grenze stoßen?

Antwort. Ja. Ein Netz ist ein Verfahren wie jedes andere; es kann die Grenze erreichen, aber nicht überschreiten. Jenseits der Grenze erkennt es nicht mehr, sondern passt sich an das Rauschen an und hält zufällige Nähe für Struktur; in der Lerntheorie heißt das Überanpassung. Hinzu kommt eine bekannte Eigenschaft solcher Netze: Sie lernen grobe, niederfrequente Strukturen zuerst und feine spät **[Q]** [4]. Feine Strukturen sind aber gerade die, die dem Rauschen am nächsten liegen.

Sprachmodelle sind in einer ungünstigeren Lage. Sie lernen aus Text, nicht aus Messsignalen, und haben keine eigene Messauflösung. Bei Zahlenverhältnissen neigen sie zu Falschtreffern: Bei genügend vielen Kombinationen findet sich fast immer eine „harmonische“ Erklärung (Look-elsewhere-Effekt). Deshalb werden im Korpus Prüfskripte als Nulltests angelegt: Liefert eine Zufallsauswahl dasselbe Ergebnis, wird es nicht gewertet. Das gilt für jeden Vorschlag eines Sprachmodells.

Besser als die Rohdaten werden Netze nur durch eingebautes Vorwissen. Dok. 359 Satz D zeigt das an einem Beispiel: Ob das Zulässigkeitskriterium „Primfaktoren nur aus $\{2, 3, 5, 7, 11, 13\}$“ lernbar ist, entscheidet die Hypothesenklasse. Ohne Strukturannahme verlangt die Lernschranke rund 84 000 markierte Beispiele, mit der Strukturannahme „Primfaktoren aus einer festen Menge“ höchstens 407; aus positiven Beispielen allein wird die richtige Primzahlmenge dann schon nach 30 Beispielen sicher erkannt **[K]** [6].

3 Warum bilden Sprachmodelle trotzdem lesbare Sätze?

Frage. Wenn das so ist, warum erzeugen Sprachmodelle kaum je unlesbare Sätze?

Antwort. Weil Grammatik und Satzbau das sind, was in den Trainingsdaten am dichtesten vorkommt. Es sind Billionen Wörter, dieselben Regeln wiederholen sich in Millionen verschiedener Sätze, es gibt kein Messrauschen, und die Architektur ist auf Abfolgen von Wörtern zugeschnitten. Das ist genau der günstige Fall aus Dok. 359 Satz D: passende Vorgabe und reichlich Beispiele.

Schwach werden die Modelle dort, wo das Muster selten oder exakt ist: genaue Zahlen, Rechenwege, seltene Fakten, Literaturangaben. Dort erzeugen sie Plausibles, und der Satz bleibt dabei flüssig. Lesbarkeit ist das dichte Muster, Richtigkeit oft das dünne. Ein gut geschriebener Satz eines Sprachmodells sagt deshalb nichts über die Richtigkeit seines Inhalts.

4 Müssten harmonische Muster nicht so dicht sein wie Grammatik?

Frage. Wenn die FFGFT zutrifft, durchziehen harmonische Verhältnisse die ganze Natur. Müssten sie dann nicht ebenso dicht vorkommen wie Grammatik?

Antwort. Dicht im Vorkommen ja, dicht in der Vielfalt nein. Für das Lernen einer Regel zählt die Zahl *verschiedener* Beispiele, nicht die Zahl der Wiederholungen. Das Elektron kommt unvorstellbar oft vor, liefert aber jedes Mal dasselbe Massenverhältnis. Die Grundstruktur der FFGFT steckt in wenigen Zahlen: einigen Massenverhältnissen, Kopplungen und Mischungswinkeln, zusammen ein paar Dutzend. Aus so wenigen Werten kann kein Verfahren eine Regel von Zufall trennen.

Wo harmonische Muster tatsächlich in großer Vielfalt vorkommen, wurden sie auch gefunden: in Atomspektren mit Tausenden Linien nach einem ganzzahligen Bauprinzip, in Kristallgittern, in Bahnresonanzen und Musikinstrumenten. Balmer fand die Regel der Wasserstofflinien 1885 aus vier Linien von Hand **[Q]** [1]; symbolische Regression hat bekannte Formeln der Physik aus Daten wiedergefunden **[Q]** [5].

Ein zweiter Grund kommt aus dem Korpus selbst. Die gemessenen Verhältnisse sind nach FFGFT keine exakten Brüche: Die Grundform ist exakt, der Messwert trägt den Einbettungsfehler (Dok. 333, Dok. 358 Satz A), und die PDG-Werte enthalten modellabhängige Anteile (Dok. 351). Ein Lernverfahren, das nur Messwerte sieht, lernt die verschobene Form, nicht die Regel darunter. In der Sprache gibt es diese Schicht nicht.

5 Der Nulltest

Frage. Lässt sich prüfen, wie viel Struktur die Messwerte selbst tragen und wie viel die Vorgabe beiträgt?

Antwort. Ja, mit einer symbolischen Regression in ihrer exakten Form, der vollständigen Suche über eine Ausdrucks-Grammatik. Durchsucht werden alle Ausdrücke

$$x = c \cdot d^{1/k} \cdot \xi^{m/n} \cdot \pi^{s},$$

mit teilerfremdem Bruch $c = p/q$, $p, q \le 200$, Wurzeln $d^{1/k}$ mit $d \le 30$ und $k \in \{2, 3\}$, $\xi = 1/7500$ mit $n \in \{1, 2, 3, 6\}$ und $|m/n| \le 4{,}5$, sowie $s \in \{-1, 0, 1\}$. Die Primfaktoren von p, q und d stammen aus einer gewählten Primzahlmenge. Mit $\{2, 3, 5, 7, 11, 13\}$ sind das 23 084 325 Ausdrücke; getrennt wird nur über die Brüche p/q gesucht (3109 Ausdrücke). Jeder Ausdruck erhält eine Komplexität in Bit, die mit Zähler, Nenner, Wurzel und Exponent wächst. Der p-Wert

ist der Anteil zufälliger Zahlen (log-gleichverteilt, eine Dekade um den Messwert), die die Grammatik bei gleicher oder geringerer Komplexität ebenso genau trifft. Treffer, die genauer sind als die Messunsicherheit, zählen nur bis zu dieser.

Mit Vorgabe. Die Formeln der Grundform aus Dok. 387 sind fest; verglichen wird mit allen gleich komplexen Ausdrücken derselben Grammatik:

Größe	Formel	Abweichung	p
v/E_P	$\xi^4/(5\pi)$	$-0{,}23\,\%$	0,02
M_W/M_Z	$\sqrt{7/9}$	$+0{,}06\,\%$	0,09
λ_{CKM}	$\xi^{1/6}$	$+0{,}45\,\%$	0,11
m_h/M_Z	$11/8$	$+0{,}15\,\%$	0,42
m_μ/m_e, m_τ/m_μ, Δm^2-Verhältnis, $\sin^2\theta_{13}$, m_t/M_Z		$0{,}1$–$1{,}5\,\%$	1,0

Zusammengefasst nach Fisher ergibt das $p = 0{,}41$ **[K]**. Bei $0{,}5$ bis $1\,\%$ Abweichung trifft die Grammatik jede Zahl; die Leptonformeln haben dort numerisch keine Beweiskraft. Am auffälligsten ist v/E_P. Für $\alpha^{-1} = 3700/27$ (Dok. 338) gilt: Die Abweichung von $7{,}6$ ppm erreicht ein Bruch mit Nenner bis 27 auch bei einer Zufallszahl in etwa der Hälfte der Fälle ($p \approx 0{,}47$) **[K]**.

Ohne Vorgabe. Die blinde Suche über dieselben neun Größen bleibt für jede Primzahlmenge auf Zufallsniveau: für $\{2, 3, 5, 7, 11, 13\}$, für die Kontrollmengen $\{2, 3, 5, 7, 17, 19\}$ und $\{2, 3, 5, 13, 17, 23\}$, für $\{2, 3, 5, 7\}$ und ebenso für reine Zufallszahlen **[K]**.

Positivkontrolle. Die Balmer-Linien des Wasserstoffs haben die exakten Verhältnisse $27/20$, $28/25$ und $200/189$; die Luftwellenlängen treffen sie auf 10^{-5} **[Q]** [7]. Mit der engen Grammatik der Brüche wird diese Regel schon aus drei Verhältnissen gefunden (zusammen $p = 0{,}002$), mit der vollen Grammatik nicht ($p = 0{,}47$) **[K]**. Die 23 Millionen Ausdrücke liegen so dicht, dass auch Zufallszahlen ebenso gut getroffen werden.

Was daraus folgt. Selbst eine wahre Regel ist aus wenigen Beispielen nur mit der richtigen, engen Vorgabe sichtbar. Die numerische Nähe trägt die FFGFT nicht; das muss die Ableitungskette tun: Geometrie, Galois-Struktur, Formel. Das entspricht der Lesart von Dok. 384 und Dok. 387, nach der die Verhältnisse der Grundform die Struktur prüfen. Widerlegt ist durch den Test nichts; er misst nur, was die Zahlen allein hergeben.

Grenzen des Tests. Das Bit-Maß der Komplexität ist eine Wahl; ein anderes Maß verschiebt die einzelnen p-Werte **[S]**. Es sind nur neun Größen. Die Formeln sind in Kenntnis der Messwerte entstanden; der Vergleich mit gleich komplexen Alternativen ist deshalb der faire Maßstab, nicht der rohe Treffer. Die Leptonreste von $0{,}5$ bis $1\,\%$ gelten im Korpus als echte Struktur (K_{frak}, Dok. 352); der Test kann sie nur als Fehltreffer werten.

6 Sprache ändert sich laufend, und trotzdem funktioniert es

Frage. Sprache ändert sich dauernd, es entstehen neue Wortbildungen, Grammatik variiert in Dialekten. Warum funktioniert es trotzdem?

Antwort. Gerade die Veränderlichkeit bestätigt das Bild. Sprache arbeitet mit großer Toleranz und liefert zugleich sehr viele Beispiele.

Zur Toleranz: Ein Satz bleibt verständlich, wenn ein Wort falsch geschrieben, ein Dialektwort eingesetzt oder die Satzstellung verdreht ist. Gedruckte Sprache ist stark redundant **[Q]** [2]. Die Genauigkeit, die Sprache braucht, ist grob; in der Sprache des Korpus: großes ε, damit kleines Q_c. Sprache lebt in dem Bereich, in dem Strukturen noch trennbar sind.

Zu den Beispielen: Neue Wortbildungen und Dialekte sind keine Einzelfälle, sondern selbst Muster mit vielen Belegen. Ein Dialekt hat Millionen Sprecher und unzählige Sätze; neue Wörter folgen alten Bauregeln, „googeln“ wird konjugiert wie „segeln“. Ein Lernverfahren lernt deshalb keine einzelne starre Grammatik, sondern eine Verteilung von Varianten,

und jede Variante ist dicht belegt. Unter den Dialekten liegt eine gemeinsame tiefere Struktur, wie bei Balmer: viele Linien, eine Regel. Wo es nicht funktioniert, passt es ebenfalls: Bei einem kleinen Dialekt mit wenig Text, einem seltenen Fachwort oder einem ganz neuen Ausdruck werden Sprachmodelle unsicher.

Die Musik zeigt beide Seiten. Die harmonische Grammatik aus Oktave, Quinte und Terz, also aus den Primzahlen 2, 3 und 5, ist universell erkennbar und hat viele „Dialekte“: reine Stimmung, gleichstufig, mitteltönig, Volksmusik-Stimmungen. Sie funktioniert, weil das Ohr Abweichungen in der Größe eines Kommas toleriert. Das ist die Aussage von Dok. 342 und Dok. 343: Bis $k \approx 3$ sind die Galois-Strukturen bei dieser Toleranz trennbar, darüber nicht mehr **[B]**. Die Harmonik der kleinen Primzahlen ist in der Natur so dicht und robust wie Grammatik. Die feinen Verhältnisse der Teilchenmassen, bei denen es auf Zehntelprozent ankommt, liegen jenseits dieser Grenze; dort muss die Struktur aus der Ableitung kommen.

7 Warum verzeiht Sprache Fehler und Zahlen nicht?

Frage. Warum lässt Sprache diese Toleranz zu, Mathematik und Zahlen aber nicht?

Antwort. Wegen der Redundanz. Nachrichtentechnisch gesprochen ist Sprache ein fehlerkorrigierender Code, eine Zahl eine uncodierte Übertragung.

Die meisten zufälligen Buchstabenfolgen sind keine Wörter. Wird ein Buchstabe falsch, entsteht meist ein ungültiges Wort, und der Empfänger korrigiert zum nächsten gültigen; Satzbau und Zusammenhang prüfen zusätzlich. Das entspricht einem Code mit großem Hamming-Abstand: Fehler werden erkannt und korrigiert. Viele Formen führen außerdem zur selben Bedeutung, und am Ziel zählt nur die Bedeutung.

Bei einer Zahl ist der Abstand null. Jede Ziffernfolge ist eine gültige Zahl; aus $137{,}036$ wird bei einem Ziffernfehler $137{,}037$, keine fehlerhafte, sondern eine andere, genauso gültige Zahl. Nichts zeigt den Fehler an, nichts korrigiert ihn. Mathematik verkettet außerdem: Ein Fehler geht in jeden folgenden Schritt ein und wird oft verstärkt, während sich Fehler in einem Satz nicht aufsummieren.

Beim Zählen ist Mathematik dagegen tolerant. Ganze Zahlen, Gruppenordnungen und Wicklungszahlen verhalten sich wie Wörter: Zwischen 3 und 4 gibt es keine gültige Gruppenordnung, und $3{,}01$ wird sofort als ungültig erkannt. Im Korpus steht das als „Zustand gegen Prozess“: Zählen ist exakt, ein Bit ist eine Wicklungszahl (Dok. 343, Dok. 247). Die algebraisch bewiesenen Aussagen der FFGFT, also $\mathbb{Z}_3$, $GF(27)$, Orbits und Fixpunkte, sind deshalb so fehlertolerant wie Sprache. Die Intoleranz entsteht an einer einzigen Stelle: beim Übergang vom Diskreten zum Kontinuum, wenn ein ganzzahliges Verhältnis mit einem Messwert auf der reellen Achse verglichen wird. Dort ist jeder Nachbarwert gültig, und es gibt keinen Abstand, der das Rauschen abfängt.

8 Schöpfen KI-Modelle aus einem fertigen Rahmenwerk?

Frage. KI-Modelle haben letztlich ein fertiges Rahmenwerk, aus dem sie schöpfen; es muss nicht alles neu nach Mustern durchsucht werden. Wie verträgt sich das mit der Rauschgrenze?

Antwort. Nach dem Training ist ein Modell tatsächlich ein fertiges Rahmenwerk; beim Antworten wird nichts mehr durchsucht, das Gelernte wird angewendet. Die Gewichte sind die eingefrorene Vorgabe, im Sinn von Dok. 359 Satz D die Hypothesenklasse.

Dieses Rahmenwerk ist aber selbst aus Daten gelernt. Es ist eine verdichtete Form der Trainingstexte und enthält nur, was dort dicht vorkam. Wo die Texte dünn waren, hat es Lücken, und das Modell füllt sie mit Plausiblem; daher kommen erfundene Literaturangaben. Es ist außerdem statistisch und nicht exakt, für Sprache gebaut und für exakte Zahlen

unzuverlässig. Moderne Systeme rufen deshalb für den exakten Teil ein Werkzeug auf: Das statistische Rahmenwerk entscheidet, was zu rechnen ist, das Werkzeug rechnet. Bei der Arbeit am Korpus ist das die Arbeitsteilung zwischen Formulierung und Prüfskript.

Auch die FFGFT ist ein fertiges Rahmenwerk: ξ, $T^4/\mathbb{Z}_3$, die Galois-Struktur. Es ist aber nicht aus Daten gelernt, sondern gesetzt und abgeleitet. Das gelernte Rahmenwerk ist breit und tolerant, aber ohne Garantie für Exaktheit; das gesetzte ist exakt und diskret, muss sich aber am Messwert bewähren, genau an der Stelle, wo Diskretes auf Kontinuum trifft. Ein Lernverfahren kann die FFGFT-Struktur nach dem Nulltest nicht selbst finden; es kann sie aber als Rahmen eingebaut bekommen, wie es die Architekturskizze von Dok. 359 vorschlägt **[S]**.

9 Woher kommen die Regeln eines KI-Assistenten?

Frage. Ein KI-Assistent arbeitet mit vielen vorgegebenen Regeln. Sind diese gelernt oder direkt eingegeben?

Antwort. Beides, in drei Schichten.

Die erste Schicht ist gelernt und macht den größten Teil aus. Zuerst entsteht beim Training an sehr vielen Texten das statistische Rahmenwerk. Danach wird in einem zweiten Training das Verhalten geformt, mit Bewertungen durch Menschen und mit schriftlich formulierten Grundsätzen wie Ehrlichkeit, Schadensvermeidung und dem Eingeständnis von Unsicherheit. Auch diese Grundsätze stecken danach in den Gewichten und werden nicht bei jeder Antwort nachgelesen.

Die zweite Schicht wird bei jedem Gespräch neu mitgegeben: Anweisungen des Produkts, etwa wie Werkzeuge benutzt werden und was nur nach Rückfrage geschehen darf, sowie gespeicherte Vorgaben des Nutzers. Diese Schicht ist am leichtesten zu ändern; sie gilt sofort, ohne neues Training. Die dritte Schicht ist der laufende Zusammenhang: alles, was im Gespräch steht und was gelesen wurde.

Die Schichten können sich widersprechen. Bei der Arbeit an diesem Korpus verlangte ein automatischer Prüfschritt nach jeder Antwort, Änderungen selbst in das öffentliche Repositorium zu übertragen, während die gespeicherte Vorgabe des Autors genau das untersagt; die ausdrückliche Vorgabe wurde befolgt. Zum Thema dieses Dokuments passt die Aufteilung: Die erste Schicht ist das gelernte, tolerante Rahmenwerk, die zweite und dritte sind gesetzte Regeln, die Prüfskripte das exakte Werkzeug, das beides kontrolliert.

10 Wie entsteht nach einer Fehlermeldung der nächste Schritt?

Frage. Zwischen einer Fehlermeldung eines Skripts und der Entscheidung, was als Nächstes am sinnvollsten ist, müssen doch viele Schichten liegen.

Antwort. Ja, aber anders, als man vermuten würde: Es gibt keinen eigenen Entscheidungsbaustein, sondern Schichten im Netz und eine einfache Schleife außen herum.

Die Schleife: Der Assistent schreibt einen Werkzeugaufruf. Das umgebende Programm führt ihn aus und hängt das Ergebnis, auch eine Fehlermeldung, an den Gesprächstext an. Dann wird das Ganze neu gelesen und der nächste Schritt geschrieben. Ein Plan existiert nur als Text in diesem Zusammenhang.

Die Schichten: Das Netz selbst hat Dutzende bis über hundert hintereinanderliegende Schichten, von denen jede den ganzen bisherigen Text weiterverarbeitet. Aus Fehlermeldung, Ziel, gelesenen Dateien und bisherigen Versuchen entsteht so der nächste Schritt. Dass er sinnvoll ist, ist trainiert: Im zweiten Training wurden solche Abläufe an vielen Aufgaben geübt, und Abläufe, die zum Ziel führten, wurden verstärkt.

Zwei Beispiele aus dem Neusatz der Buchreihe: Eine Meldung „Improper alphabetic constant“ beim Setzen eines Kapiteltitels mit φ ist ein dicht belegtes Muster; die Ursache, Mathematik in den PDF-Lesezeichen, wird sofort erkannt. Ein Band, der ohne Fehlermeldung nur 18 statt über 300 Seiten ergab, verlangte dagegen einen Schluss: Die Eingabe endete zu früh, vermutlich durch ein `\end{document}` in einem Kapitel, was eine Suche bestätigte. Wo die Muster dünn sind, wird probiert, und es braucht mehrere Anläufe. Deshalb gilt für den Assistenten dasselbe wie für die FFGFT: ausprobieren, exakt prüfen, mit Prüfskripten nachmessen, statt dem eigenen Eindruck zu trauen.

11 Zufall und Wahrscheinlichkeit

Frage. Spielt bei Zufall und Wahrscheinlichkeiten die Rauschgrenze nicht ebenfalls eine Rolle?

Antwort. Ja, sogar ganz direkt: Die Wahrscheinlichkeitsrechnung ist die Mathematik der Rauschgrenze. Dabei sind zwei Arten von Wahrscheinlichkeit zu unterscheiden.

Wahrscheinlichkeit als Nichtwissen: Ein Messwert schwankt. Mittelt man N unabhängige Messungen, sinkt das Rauschen wie $1/\sqrt{N}$; die hundertfache Zahl von Messungen senkt es auf ein Zehntel **[B]**. Deshalb ist m_μ/m_e auf 10^{-8} bekannt, obwohl jede einzelne Messung gröber ist. Das gilt nur für zufällige Fehler; systematische Anteile wie die Modellannahmen der PDG-Werte (Dok. 351) mitteln sich nicht weg. Auch der p-Wert des Nulltests gehört hierher: Er ist die Rauschgrenze in Wahrscheinlichkeit ausgedrückt.

In Sprachmodellen ist Wahrscheinlichkeit die Ausgabe selbst. Bei jedem Wort wird eine Verteilung über alle möglichen nächsten Wörter berechnet und eines ausgewählt. Wo die Trainingsdaten dicht waren, ist die Verteilung scharf und die Antwort stabil; wo sie dünn waren, ist sie flach, und die Auswahl entscheidet beinahe der Zufall. Eine flache Verteilung ist die Rauschgrenze des Modells, und von außen ist sie nicht zu sehen, weil der Satz trotzdem flüssig klingt.

Wahrscheinlichkeit als Struktur: In der Quantenmechanik sind Wahrscheinlichkeiten exakte Zahlen. Nach Dok. 367 sind die Koide-Phase θ und die ikosaedrische Übergangswahrscheinlichkeit p_0 derselbe Quotient $2/3^2 = 2/9$, zwei Lesarten einer Born-Regel-Struktur. Eine solche Wahrscheinlichkeit ist so diskret wie eine Gruppenordnung. Rauschen kommt erst bei der Messung hinzu: Eine Häufigkeit aus N Ereignissen streut um $2/9$ mit etwa $\sqrt{p(1-p)/N}$; um $2/9$ auf drei Standardabweichungen vom Nachbarbruch $1/5$ zu trennen, braucht es rund 3200 Ereignisse **[K]**. In diesem Sinn führt Dok. 230 auch die Bell-Korrelationen: real, aber geometrisch strukturiert. Wahrscheinlichkeit kommt damit zweimal vor: als Gegenstand der Theorie, exakt, und als Werkzeug, um zu beurteilen, ob das Exakte im Rauschen noch erkennbar ist.

12 Fließt die Rauschgrenze in die Gewichte ein?

Frage. Wie ist das mit den Gewichten eines Netzes: Fließen dort die Rauschgrenzen ein?

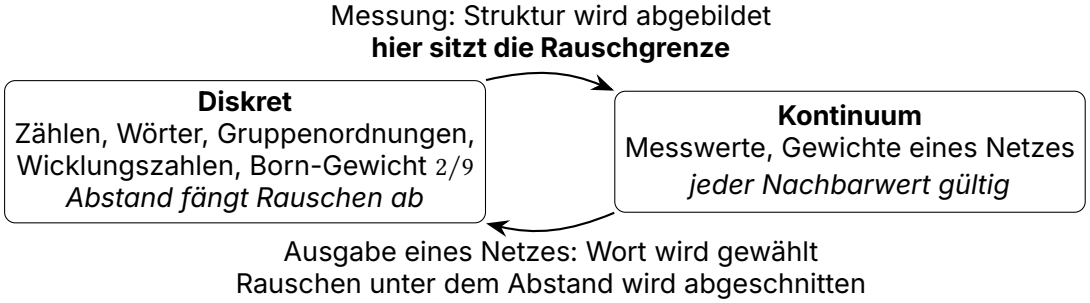
Antwort. Ja, auf zwei Wegen, und die Gewichte sind selbst ein Beispiel für das Prinzip.

Beim Lernen werden die Gewichte in vielen kleinen Schritten angepasst, jeder nach einem kleinen Stapel von Beispielen und deshalb verrauscht. Was oft vorkommt, schiebt die Gewichte immer wieder in dieselbe Richtung und setzt sich durch; das Rauschen mittelt sich mit $1/\sqrt{N}$ weg. Was selten vorkommt, geht im Rauschen der Schritte unter. Dazu kommen gezielt eingebaute Bremsen: Gewichte werden klein gehalten, und das Training wird rechtzeitig beendet. Damit wird bewusst eine Rauschgrenze gesetzt: Feinstruktur, die nicht oft genug belegt ist, soll nicht gelernt werden, weil sie meist Rauschen ist.

Beim Speichern ist jedes einzelne Gewicht erstaunlich ungenau. Mit 16 Bit sind es etwa $2{,}4$ bis $3{,}3$ Dezimalstellen **[K]**, und oft wird nachträglich auf 8 oder 4 Bit gekürzt, ohne dass das Modell merklich schlechter wird. Das geht nur, weil das Wissen nicht in einzelnen Gewichten steckt, sondern verteilt in sehr vielen zugleich. Das Netz ist damit selbst ein redundanter, fehlertoleranter Code, wie die Sprache. Gute Trainingslösungen haben genau diese Eigenschaft: Eine kleine Verschiebung der Gewichte ändert das Ergebnis kaum **[Q]** [3]. Die Kehrseite ist dieselbe wie bei der Sprache: Exakte Rechnungen, die an jeder Stelle volle Genauigkeit verlangen, gelingen im Inneren schlecht.

13 Der gemeinsame Kern in einem Bild

Alle Antworten laufen auf dieselbe Struktur hinaus. Auf der diskreten Seite stehen Zählen, Wörter, Gruppenordnungen, Wicklungszahlen und Born-Gewichte; dort gibt es Abstände zwischen den gültigen Werten, und Rauschen, das kleiner ist als dieser Abstand, wird abgefangen. Auf der kontinuierlichen Seite stehen Messwerte und die Gewichte eines Netzes; dort ist jeder Nachbarwert gültig.



Ein Netz rechnet im Inneren kontinuierlich und gibt diskrete Wörter aus; beim Schritt vom Kontinuum zum Diskreten wird das Rauschen abgeschnitten, solange es kleiner ist als der Abstand zwischen zwei Wörtern. Bei der Messung läuft es umgekehrt: Eine exakte, diskrete Struktur wird auf das Kontinuum abgebildet, und dort fängt kein Abstand das Rauschen ab. Daraus folgen die drei Kernsätze dieses Dokuments:

1. Diskrete Struktur ist fehlertolerant; die Rauschgrenze sitzt am Übergang vom Diskreten zum Kontinuum **[B]**.
2. Struktur, die in den Daten dicht und vielfältig belegt ist, wird gelernt; Struktur aus wenigen exakten Werten wird aus Daten nicht gefunden, auch von einem Netz nicht **[K]**.
3. Solche Struktur muss vorgegeben und dann geprüft werden: Setzung, Ableitung, Vergleich mit dem Messwert, Nulltest. Diesen Weg geht die FFGFT **[S]**.

Prüfskripte: `2/python/Dok393_Skripte/` — `pruef_393a_nulltest_grammatik.py` (8/8, Ergebnisprotokoll `pruef_393a_ergebnis.txt`), `pruef_393b_zahlen.py` (11/11); zusammen `run_all_393.sh`, 19/19.

Werkzeug und Methode

Claude (Anthropic) wurde als Werkzeug eingesetzt für: Ausformulieren der Antworten nach den Fragen des Autors, Schreiben und Ausführen der Prüfskripte und Ausarbeiten der LaTeX-Quellen. Die Abschnitte über die Arbeitsweise von KI-Assistenten beschreiben die allgemeine Funktionsweise solcher Systeme; sie beruhen nicht auf einer Einsicht in die

eigenen Gewichte. Jede Zahl im Text ist durch eine Prüfung in den genannten Skripten abgesichert; Literaturangaben sind als **[Q]** markiert.

Literaturverzeichnis

[1] J. J. Balmer, *Notiz über die Spectrallinien des Wasserstoffs*, Annalen der Physik **261** (1885) 80–87.

[2] C. E. Shannon, *Prediction and entropy of printed English*, Bell System Technical Journal **30** (1951) 50–64.

[3] S. Hochreiter, J. Schmidhuber, *Flat minima*, Neural Computation **9** (1997) 1–42.

[4] N. Rahaman u. a., *On the spectral bias of neural networks*, Proceedings of the 36th International Conference on Machine Learning, PMLR **97** (2019) 5301–5310.

[5] S.-M. Udrescu, M. Tegmark, *AI Feynman: A physics-inspired method for symbolic regression*, Science Advances **6** (2020) eaay2631.

[6] S. Shalev-Shwartz, S. Ben-David, *Understanding Machine Learning: From Theory to Algorithms*, Cambridge University Press (2014).

[7] A. Kramida, Yu. Ralchenko, J. Reader, NIST ASD Team, *NIST Atomic Spectra Database*, National Institute of Standards and Technology, Gaithersburg (Wasserstofflinien Hα–Hδ, Luftwellenlängen).